

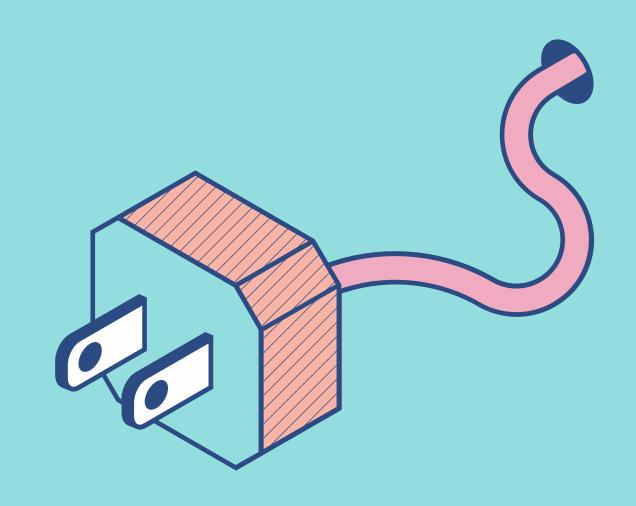
# Challenge Platinum: API for Sentiment Analyst

### Nama:

I Gede Dhani Pradipta Putra Junio Faathir Anand Ansyori Mohammad Raditya Syahmaulana

## Summary

Melakukan analisis sentimen dengan pembuatan model menggunakan Naural Network dan LSTM dengan mendeploynya dengan API Flask dan Swagger UI. Pada endpoint dapat menginput teks dan mengupload file untuk menganalisis sentimen dan meng cleansingnya. Data yang di upload diberikan oleh pihak binar



## Roadmap Pembuatan Model

1 -

### **Prepare Dataset**

Menganalisa data, dan melihat label jumlah positif, negatif, dan netral. 2

### **Cleansing Text**

Membersihkan
teks dengan
menggunakan
cleansing
function.

## Feature Extraction

Mengubah setiap kata menjadi vector menggunakan CountVectorizer(N N) dan Tokenizer(LSTM).

## Roadmap Pembuatan Model

4

# Prepare and Validation Data

Menentukan jumlah data yang akan di train dan di test

5

#### **Model Selection**

Untuk NN
menggunakan
MLPClassifier from
sklearn dan LSTM
menggunakan deep
learning seperti
TensorFlow

6

# Training Model dan Save Model

Melakukan training dan validation data setelah itu melakukan saving data

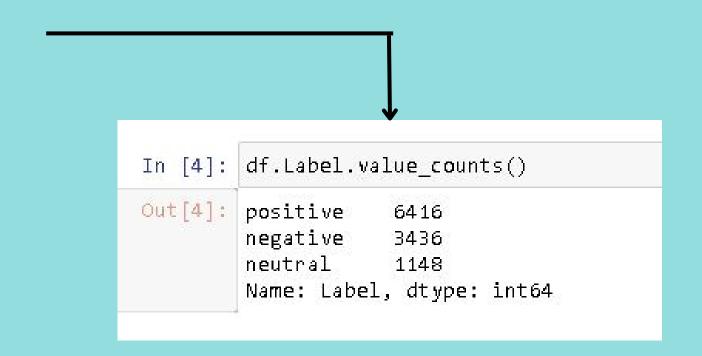
### Hasil Model Dari Neural Network

• Terdapat 11000 data label yang terdiri dari:

1. Positive : 6416

2. Negative : 3436

3. Netral : 1148



Melakukan Cleansing menggunakan function!

```
In [5]: def cleansing(sent):
    # Mengubah kata menjadi huruf kecil semua dengan menggunakan fungsi lower()
    string = sent.lower()
    # Menghapus emoticon dan tanda baca menggunakan "RegEx" dengan script di bawah
    string = re.sub(r'[^a-zA-Z0-9]', ' ', string)
    return string
```

Melakukan Feature Extraction

```
In [9]: # Untuk melakukan Feature Extraction, kita menggunakan library "Sklearn atau scikit-learn".
# Sklearn adolah library untuk melakukan task-task Machine Learning.
# "CountVectorizer" merupakan salah satu modul untuk melakukan "BoW"

from sklearn.feature_extraction.text import CountVectorizer

# Kita proses Feature Extraction
count_vect = CountVectorizer()
count_vect.fit(data_preprocessed)

X = count_vect.transform(data_preprocessed)
print ("Feature Extraction selesai")
Feature Extraction selesai
```

Menentukan Data Yang Akan Di Train Dan Validation

```
Split dataset menjadi 80% untuk train dan 20% untuk test.

In [24]: from sklearn.model_selection import train_test_split
    classes = df.Label

In [26]: classes[0:5]

Out[26]: 0 positive
    1 neutral
    2 positive
    3 positive
    4 negative
    Name: Label, dtype: object

In [13]: X_train, X_test, y_train, y_test = train_test_split(X, classes, test_size = 0.2)
```

Melakukan Saving CountVectorizer

```
In [23]: import pickle
pickle.dump(count_vect, open("feature.pkl", "wb"))
```

Melakukan Saving Model Neural Network

```
In [15]: pickle.dump(model, open("model.pkl", "wb"))
```

### Hasil Model Dari LSTM

Terdapat 11000 data label yang terdiri dari :

1. Positive : 6416

2. Negative : 3436

3. Netral : 1148

In [57]: df.label.value\_counts()
Out[57]: positive 6416
 negative 3436
 neutral 1148
 Name: label, dtype: int64

Melakukan Cleansing menggunakan functionl

```
def fun(txt):
    txt = str(txt).lower()
    txt = re.sub("[,]", ",", txt)
    txt = re.sub("[,]", ", txt)
    txt = re.sub("[,]", ", txt)
```

```
txt = " ".join(txt)
    txt = re.sub(" ,", ",", txt)
    txt = re.sub(" \.", ".", txt)
    txt = re.sub(" \?", "?", txt)
    txt = re.sub(" !", "!", txt)
    txt = re.sub(" \"", "\"", txt)
    return txt

df_baru['content'] = df_baru['content'].apply(lambda txt : fun(txt))

df_baru.head()
```

```
for word in txt :
    if word in alayOri :
        txt[txt.index(word)] = txt[txt.index(word)].replace(word, alayFix[alayOri.index(word)])
```

Melakukan Feature Extraction

```
tokenizer = Tokenizer(num_words=5000, oov_token='x')
tokenizer.fit_on_texts(x)

sekuens_x = tokenizer.texts_to_sequences(x)

padded_x = pad_sequences(sekuens_x)
```

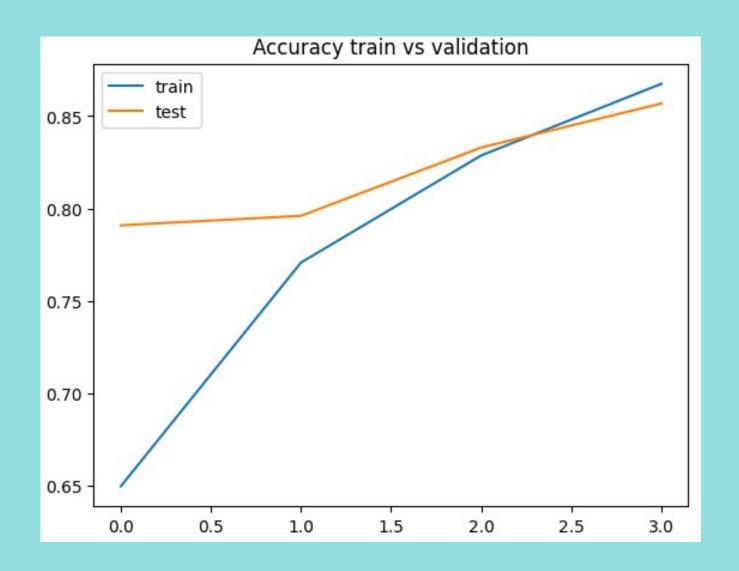
Melakukan Train Dan Validation

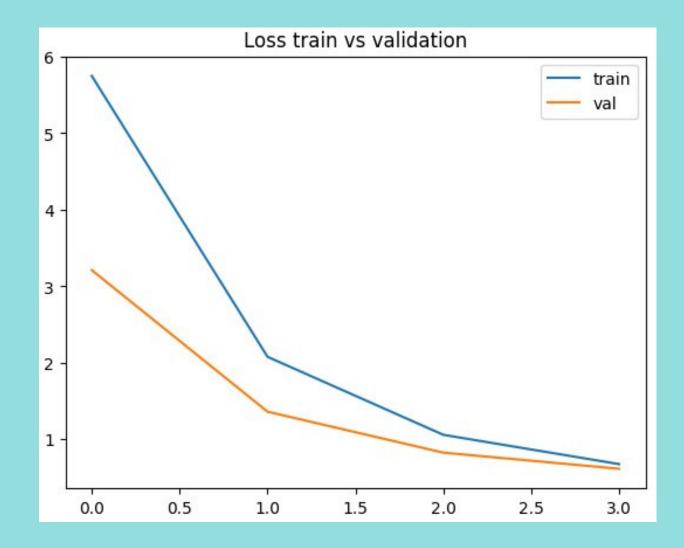
```
In [53]: %%time
   fit = model.fit(x train,
          y train,
          batch size = 10,
          epochs=100,
          validation_data=(x_val, y_val),
           validation split=0.2,
          callbacks = [callbacks]
    Epoch 1/100
   categorical accuracy: 0.7909
    Epoch 2/100
   categorical_accuracy: 0.7960
    Epoch 3/100
   categorical accuracy: 0.8330
    Epoch 4/100
   categorical accuracy: 0.8568
   CPU times: total: 5min 20s
    Wall time: 1min 35s
```

#### Model dan Hasil Validation Data

```
model = tf.keras.Sequential([
    tf.keras.layers.Embedding(input dim=5000, output dim=64),
    tf.keras.layers.LSTM(64),
   tf.keras.layers.Dense(64, kernel regularizer=L1L2(l1=0.01, l2=0.01), activation='relu'),
    tf.keras.layers.Dropout(0.1),
   tf.keras.layers.BatchNormalization(),
    tf.keras.layers.Dense(64, kernel regularizer=L1L2(l1=0, l2=0.01), activation='relu'),
   tf.keras.layers.Dropout(0.1),
   tf.keras.layers.BatchNormalization(),
   tf.keras.layers.Dense(64, kernel regularizer=L1L2(l1=0, l2=0.01), activation='relu'),
   tf.keras.layers.Dropout(0.1),
    tf.keras.layers.BatchNormalization(),
   tf.keras.layers.Dense(64, kernel regularizer=L1L2(l1=0, l2=0.01), activation='relu'),
   tf.keras.layers.Dropout(0.1),
    tf.keras.layers.BatchNormalization(),
   tf.keras.layers.Dense(64, kernel regularizer=L1L2(l1=0, l2=0.01), activation='relu'),
   tf.keras.layers.Dropout(0.1),
   tf.keras.layers.BatchNormalization(),
    tf.keras.layers.Dense(3, activation='softmax')
1)
```

### Hasil Akurasi dan Loss



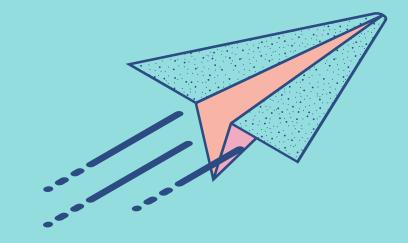


Melakukan Saving Model dan Tokenizer

```
In [21]: filename = 'lstm.h5'
model.save(filename)

In [22]: tokenizer_json = tokenizer.to_json()
with io.open('tokenizer.json', 'w', encoding='utf-8') as f:
    f.write(json.dumps(tokenizer_json, ensure_ascii=False))
```

# Conclusion



Machine Learning mampu mengklasifikasikan sentimen dari ribuan data tweet dalam hitungan menit. Meskipun akurasinya hanya 84% - 87%, Machine Learning mampu melakukan sentimen dalam waktu yang cepat.

